

VAE-MAD-GAN FOR HIDS

TIM KAEUBLE

ScaDS-AI

November 2020 –

ABSTRACT

Short summary of the contents in English...a great guide by Kent Beck how to write good abstracts can be found here:

<https://plg.uwaterloo.ca/~migod/research/beck00PSLA.html>

ZUSAMMENFASSUNG

Kurze Zusammenfassung des Inhaltes in deutscher Sprache...

CONTENTS

1	EXPOSEE	3	
1.1	Einleitung	3	
1.2	Zielsetzung	4	
2	GRUNDLAGEN	7	
2.1	Anomalien und Anomalieerkennung	7	
2.2	Intrusion Detection System	8	
2.2.1	Datenanalyse	8	
2.2.2	Datenerfassung	9	
2.3	System Calls	10	
2.4	Datensatz	12	
2.5	Künstliche neuronale Netze	14	
2.5.1	Rekurrente neuronale Netze	14	
2.5.2	Long Short-Term Memory	16	
3	VERWANDTE ARBEITEN	21	
3.1	Anomaliedetektion mit System Calls	21	
3.2	Untersuchen von Zeitreihen mit LSTM	21	
4	REALISIERUNG	23	
4.1	Verwendete Tools	23	
4.2	Vorverarbeitung	23	
4.2.1	Thread Awareness	23	
4.2.2	Embedding	23	
4.2.3	System Call Argumente	24	
4.2.4	Parameterwahl	24	
4.3	Algorithmus	24	
4.4	Anomalieerkennung	25	
4.4.1	Schwellwertbestimmung	25	
4.5	Strukturierung der Experimente	25	
4.5.1	Faktor Zeit	25	
4.5.2	Optimale Parameter	26	
4.6	Metriken	27	
5	IMPLEMENTIERUNG	29	
5.1	Erstellen der Trainingsdaten	29	
5.1.1	w2v	29	
5.1.2	Parameterinfo	29	
6	ERGEBNISSE	31	
6.0.1	Optimale Parameter	31	
7	FOLGERUNGEN	33	
	BIBLIOGRAPHY	34	

EXPOSEE

1.1 EINLEITUNG

Notes :

- solarwinds as introduction
- use advances of sequence detection from NLP
- NIDS vs. HIDS
- signature vs. anomaly based
- Forrest et al 1996 erstmals syscall traces
- low level interactions between program and kernel

Angriffe auf Computersysteme bestehen schon seit diversen Jahren. Die häufig verwendeten auf Blacklists basierenden Abwehrmechanismen reichen nicht aus um viele drohende Gefahren abzuwenden. Das liegt hauptsächlich daran, dass weder Abwandlungen von Angriffen, noch unbekannte Angriffe erkannt werden können. Ein wesentlicher Vorteil liefert hier die Angriffserkennung über Anomalien. Im Gegensatz zu dem erwähnten Blacklist Ansatz, muss nicht jeder Angriff der abgewehrt werden soll bekannt sein. Stattdessen wird versucht das Normalverhalten eines Systems zu ermitteln und jegliche Abweichung als Anomalie einzustufen. Nun bieten verschiedene Systeme verschiedene charakteristische Merkmale um das Verhalten zu beschreiben. Eine häufig verwendete Information für die Charakterisierung bieten zum Beispiel System-Logs [11].

In dieser Arbeit werden System-Calls verwendet. Sie bieten eine sehr abstrakte Betrachtung auf Betriebssystemebene. Programme auf einer Festplatte können meist erst Schaden anrichten, sobald sie ausgeführt werden. Dabei führen sie betriebssystemspezifische System-Calls aus, welche über verschiedene Tools wie zum Beispiel Sysdig [26] ausgelesen werden können. Die Schwierigkeit im Vergleich zu dem Untersuchen der Logs besteht darin, die großen Datenmengen zu bewältigen, welche schon bei kleineren Anwendungen anfallen. Die Probleme in der Verarbeitung von sehr großen Datenmengen konnten unter anderem durch die Verwendung selbst lernender Algorithmen erfolgreich angegangen werden. Im realen Einsatz solcher Verteidigungsmechanismen besteht eine weitere Schwierigkeit darin, dass das IDS Zugriff auf den Kernel des zu überwachenden Systems benötigt. Diese wird in dieser Arbeit allerdings nicht behandelt, da lediglich die

Algorithmen selbst, jedoch nicht die praktische Umsetzung in einem potentiellen Betrieb betrachtet wird.

In verschiedenen Arbeiten wurden bereits die Abfolge von System-Calls betrachtet, doch nur in wenigen Arbeiten werden auch die Parameter zur Anomalieerkennung verwendet. Eine der ersten Arbeiten von Forrest et. al [6] betrachtet lediglich die Sequenzen der System-Calls. Maggi et al. verwenden zusätzlich auch Parameter und verweisen in ihrer Arbeit [19] auf diverse verschiedene Ansätze. In dieser Arbeit soll versucht werden die Hinzunahme eines Parameters, wie zum Beispiel den Dateipfad (sofern vorhanden) bei schreibenden und lesenden Befehlen, mit Hinblick auf die Erkennungsquote des IDS zu untersuchen.

Nachdem definiert wurde welche Information untersucht wird, stellt sich zu Beginn der Entwicklung einer Anomalieerkennung die Frage, wie das Normalverhalten der Systeme erfasst werden soll. Abstrakt betrachtet werden bei der Untersuchung von System-Calls zeitvariante und potentiell multivariate Datenstreams betrachtet, sofern neben der eigentlichen Sequenz noch weitere Parameter betrachtet werden. Besonders erfolgreich haben sich dabei Long-Short-Term-Memory (LSTM) Netzwerke gezeigt. Sie haben den Vorteil auch Zusammenhänge mit größerer zeitlicher Verzögerung noch zu erkennen [13] und können in unterschiedlichsten Architekturen einen Nutzen bringen.

1.2 ZIELSETZUNG

In dieser Arbeit sollen zwei Forschungsfragen verfolgt werden.

- Kann der Erfolg von LSTM-Netzwerken in verschiedenen Bereichen auf die Erkennung von Anomalien in der Cyber-Sicherheit übertragen werden?
- Kann die Zunahme von Parametern bei der Anomalieerkennung mittels System-Calls eine Verbesserung bringen?
→ Welche Parameter kommen in Frage?

Um diese Forschungsfragen angemessen behandeln zu können müssen zunächst Grundlagen aus verschiedenen Bereichen gelegt werden. Zum einen werden unterschiedliche Herangehensweisen zur Überwachung von Systemen betrachtet und erläutert wieso es für diese Anwendung sinnvoll ist eine Host-Based Intrusion Detection zu wählen. Speziell soll auch beschrieben werden, warum sich System-Calls zur Überwachung von Computersystemen eignen. Des Weiteren müssen Grundlagen für die in dem verwendeten Algorithmus verwendeten Techniken gelegt werden. Dazu gehören hauptsächlich Grundlagen zu rekurrenten neuronalen Netzen (RNN) sowie die Erweiterungen der LSTM Netzwerke.

Ein großer Teil der Implementierungsarbeit jedoch wird die Vorverarbeitung der Daten darstellen. Diese soll mit der genaueren Unter-

suchung der Zusammensetzung der Techniken für den Algorithmus in einem weiteren Kapitel dargestellt werden. Nachdem die verwendete Software analysiert wurde, wird eine Auswertung auf dem LID-DS [16] Datensatz durchgeführt. Dieser bietet den Vorteil, dass in einer reproduzierbaren Art System Calls aufgenommen wurden. Des Weiteren werden zusätzlich die System Call Parameter, wie zum Beispiel die *Thread ID* zur Verfügung gestellt.

Im letzten Teil der Arbeit soll dann eine Schlussfolgerung aus den zuvor gewonnenen Ergebnissen gezogen werden. Hauptsächlich sollen die gestellten Forschungsfragen untersucht werden. Konnte mit einem hinzugezogenen Parameter ein Mehrwert erzielt werden? Bieten sich LSTM-Netzwerke auch für die Anomalieerkennung im IT-Sicherheitsbereich an?

In den folgenden Kapiteln sollen nun Grundlagen betrachtet werden, welche bei der Umsetzung des IDS nötig sind. Essentiell dabei sind zum einen die Definition von Anomalien und der Anomaliedetektion (siehe Kapitel 2.1) und eine allgemeine Einführung in den Bereich der IDS (siehe Kapitel 2.2). Dabei wird auf den im praktischen Teil verwendeten Ansatz der *Host-Based Intrusion Detection Systems* (HIDS) genauer eingegangen. Nachdem so eine allgemeine Herangehensweise an die Erkennung von Angriffen dargelegt wurde, soll im Anschluss die Grundlagen des verwendeten Algorithmus untersucht werden. Dazu gehören rekurrente neuronale Netze (RNN), sowie die Erweiterung der RNNs die *Long Short-Term Memory* neuronalen Netzen (LSTM).

2.1 ANOMALIEN UND ANOMALIEERKENNUNG

Muster in einem Datensatz welche nicht einem wohldefinierten Normalverhalten entsprechen werden Anomalien genannt. Ziel einer Anomalieerkennung ist es folglich Muster in Daten wiederzuerkennen welche von einem definierten Normalverhalten abweichen [3]. Die Bedeutung der Anomalieerkennung liegt in der Tatsache begründet, dass Anomalien in Daten zu signifikanten und oft kritischen Veränderungen eines System führen können. So kann eine Anomalie in Netzwerkdaten dafür stehen, dass ein gekapeter Computer sensitive Daten an ein unautorisiertes Ziel sendet [15].

Anomalien in den Daten können aus verschiedenen Gründen entstehen, zum Beispiel durch böswillige Aktivitäten oder aber auch durch Programmfehler. Doch alle Anomalien haben gemein, dass sie ein Abweichen eines definierten Normalverhalten zeigen und damit interessant für Analysen sind. Generell kann die Anomalieerkennung in zwei Phasen aufgeteilt werden, die *Trainingsphase* sowie die *Testphase*. In der ersten Phase wird versucht ein Modell des Programmverhaltens zu ermitteln und in der zweiten soll dieses Modell dann überprüft werden. Speziell soll dabei mit noch nicht betrachteten Daten die Generalisierung des Modells getestet werden. Dabei liefert der Algorithmus für jede Eingabe einen Anomaliescore. Liegt dieser über einem festgelegten Schwellwert so gilt die Eingabe als „anormal“ ansonsten als „normal“. Die Trainingsphase wird von Chandola et al. [3] weiter unterteilt in *Supervised*, *Semisupervised* sowie *Unsupervised Anomaly Detection*. Diese unterscheiden sich hauptsächlich in der Anforderung an den Datensatz. Bei einer *Supervised* Anomalieerkennung werden Trainingsdaten benötigt in welchen Anomalien sowie auch

Normalverhalten gelabelt sind. Hingegen wird beim *Semisupervised* Verfahren lediglich ein Datensatz benötigt, welcher das Normalverhalten kennzeichnet. Bei der *Unsupervised Anomaly Detection* werden Daten verwendet welche keine Labels beinhalten. Dabei wird davon ausgegangen, dass Normaldaten sehr viel umfangreicher in den Daten vertreten sind als Anomalien, da es sonst häufig zu Fehlalarmen kommen kann [24]. Bei der Umsetzung der Anomaliedetektion ergeben sich allerdings einige Schwierigkeiten:

- *Definition des Normalverhaltens*: Ziel ist es jegliches Verhalten, welches kein anormales beinhaltet, zu erfassen. So muss dafür gesorgt werden, dass das Normalverhalten auch tatsächlich in den Daten widergespiegelt wird.
- *Dynamik des Normalverhaltens*: Normalverhalten kann sich über die Zeit verändern und somit vom Algorithmus Gelerntes unbrauchbar machen [3].
- *Datensätze*: Gelabelte Daten zur Erfassung des Normalverhaltens sind oft veraltet oder nicht sehr detailreich.
- *Schwellwert*: Festlegung eines Schwellwertes, welcher die eigentliche Unterscheidung zwischen Normalverhalten und Angriffsverhalten umsetzt.

Mehr dazu in
Abschnitt 2.4

2.2 INTRUSION DETECTION SYSTEM

zu dt. Eindringung

Eine *Intrusion* ist eine unauthorisierte Aktivität, welche einem System Schaden zufügen kann. Eine *Intrusion Detection* Software/Hardware versucht automatisch diese unauthorisierten Aktivitäten zu identifizieren, um dadurch die Sicherheit des Systems gewährleisten zu können. [17] Um solche unauthorisierte Aktivitäten erkennen zu können müssen zunächst Daten erfasst werden und diese dann analysiert werden. In den folgenden beiden Abschnitten sollen diesen beiden Schritte genauer untersucht werden.

2.2.1 Datenanalyse

Das Erkennen von Angriffen auf Computersystemen mittels IDS wird meist, wie auch in [17] und [14], in drei Kategorien eingeteilt. Dazu zählen die signaturbasierten und anomaliebasierten Verfahren auf die im Folgenden eingegangen wird, sowie die *Stateful Protocol Analysis*.

zu dt.
Zustandsorientierte
Protokoll Analyse

SIGNATURBASIERT Signaturbasierte IDS (SIDS) versuchen ihnen bekannte Muster von Angriffen in den zu überwachenden Systemen wiederzuerkennen. Dies basiert darauf eine ausgeprägte Datenbank an bekannten Signaturen von Angriffen zu besitzen. Verschiedene

Methoden vergleichen dann aktuelle Signaturen des Systems mit der Datenbank. Es gibt auch hier diverse Methoden wie diese Signaturen erstellt werden. Dazu zählen zum Beispiel das Betrachten von *Host-Logs*, oder ein wenig ausgefeilter das Erstellen von *State Machines* [20]. Doch ein wesentlicher Nachteil der signaturbasierten IDS liegt in der Tatsache, dass keinerlei neuartigen Angriffe, sowie viele Abwandlungen von Angriffen nicht erkannt werden, da diese noch nicht in der Datenbank vorhanden sind. [14]

ANOMALIEBASIERT Im ersten Schritt der anomaliebasierten IDS (AIDS) wird ein Modell des Normalverhaltens erstellt. Dabei können ML-basierte, Statistik-basierte oder auch *Knowledge*-basierte Algorithmen verwendet werden. Jeder signifikante Unterschied des aktuellen Systemzustand zu dem entworfenen Modell zu einem Zeitpunkt t wird dann als Anomalie eingestuft. Jede Anomalie gilt dann wiederum als Intrusion. Grundannahme dieser Methode liegt darin, dass Intrusions von dem gelernten Normalverhalten des Systems unterschieden werden können. Die generelle Vorgehensweise und Problematiken wurden bereits in Abschnitt 2.1 besprochen. Auch wenn sich die verschiedenen Teilbereiche der AIDS stark unterscheiden, haben sie einen wesentlichen Vorteil gegenüber den SIDS. Denn ihnen ist es nicht generell verwehrt Zero-Day Angriffe zu erkennen, also Angriffe die in dieser Form noch nicht bekannt waren. Zusätzlich ist es für Angreifende schwer zu ermitteln wie das AIDS Normalverhalten definiert und diese Definitionsgrenzen auszunutzen um unerkannte Angriffe durchzuführen. Jedoch ergibt sich im Vergleich zu den SIDS eine andere Problematik. Denn die AIDS müssen einen Schwellwert festlegen ab welchem ein Vorkommnis als Anomalie erkannt wird. Dieser Wert entscheidet über die Ergebnisqualität der AIDS und sollte daher sorgfältig und am besten automatisch ermittelt werden. Eine weitere Schwierigkeit bei AIDS liegen wie in Abschnitt 2.1 erwähnt in der Ermittlung von Daten für das Normalverhalten und die damit verbundene Gefahr, dass bei nicht kompletten Erfassen des Normalverhalten viele Fehlalarme entstehen können.

Daher ist eine entscheidende Frage bei Verwendung von AIDS: Woher kommen die für das Lernen des Normalverhalten benötigten Daten?

zu dt.
Wissens-basierte

mehr dazu in
Kapitel 4.3

2.2.2 Datenerfassung

Die Datenerhebung wird in verschiedener Literatur in zwei Kategorien unterteilt [14], [17]. Zum einen die *Host Based Intrusion Detection* (HIDS) und zum anderen die *Network Based Intrusion Detection* (NIDS). In den folgenden Abschnitten werden diese beiden Ansätze genauer untersucht.

NETWORK BASED INTRUSION DETECTION Überwacht den Netzwerkverkehr über Pakete, NetFlow oder andere Netzwerkdaten. Ein großer Vorteil daran ist, dass viele Computer in einem Netzwerk überwacht werden. Ziel ist es dabei Angriffe möglichst früh zu erkennen und zu verhindern, dass sich die Gefahr weiter ausbreiten kann. Doch der erwähnte Vorteil kann schnell zu einem Nachteil werden, da bei besonders großen Netzen der hohe Datendurchsatz dafür sorgen kann, dass Angriffe übersehen werden können. [2] Ein weiterer Nachteil bei der Untersuchung von Netzwerkpaketen oder ähnlichem besteht darin, dass der Netzwerkverkehr meist verschlüsselt ist und somit nicht auf den Inhalt der Pakete eingegangen werden kann.

HOST BASED INTRUSION DETECTION Wie der Name bereits impliziert konzentriert sich HIDS auf die Untersuchung von Daten welche auf dem Host basieren. Es wird versucht das dynamische Verhalten sowie den Zustand des Systems zu überwachen und dies nur mit Informationen die auf dem Host zugänglich sind. In der Literatur werden hierfür verschiedene Informationsquellen genutzt. Dazu gehören verschiedene Logs, z.B Firewall und Database Logs [14], oder aber auch Daten aus dem Kernel wie z.B. System Calls [19]. Im Gegensatz zur NIDS kann hier auf den Inhalt von jeder Information eingegangen werden, da die interne Kommunikation unverschlüsselt stattfindet.

Abbildung 2.1 soll einen Überblick über die in den vorigen Abschnitten gemachte Einstufung geben. Die dicker umrandeten Verfahren werden in dieser Arbeit verwendet. Also zur Datenerfassung werden nur Informationen welche auf dem Host zugänglich sind verwendet und die so erhaltenen Daten werden anomaliebasiert untersucht. Es stellen sich beim designen von anomaliebasierten HIDS zwei Hauptfragen:

- Mit welchen Daten kann das Systemverhalten möglichst präzise dargestellt werden?
 - Logs, System Calls, ...
- Wie wird die eigentliche Anomalie in den Daten erkannt?

Die erste Frage soll in dem folgenden Kapitel mit der Betrachtung von System Calls zur Beschreibung des Systemverhaltens angegangen werden. Die letztere soll dann speziell in Kapitel 4.3 beleuchtet werden.

2.3 SYSTEM CALLS

Jegliche Programme die auf einem Rechner mit einem Betriebssystem laufen müssen mit diesem interagieren um Veränderungen am System vornehmen zu können. Diese Interaktion findet in Form von *System Calls* statt. Zu ihnen gehören zum Beispiel die folgenden System Calls:

zu dt. *Systemaufrufe*




Figure 2.1: Einordnung des verwendeten IDS (breiter markiert).

System Calls		
Name	Beschreibung	Argumente
open	Öffnet die in <i>path</i> spezifizierte File und gibt einen <i>file descriptor</i> zurück.	<i>path, flags, mode</i>
write	Schreibt bis zu <i>count</i> Bytes aus dem Buffer (ab Stelle <i>buf</i>) in die File, welche über den <i>file descriptor fd</i> definiert wird.	<i>fd, *buf, count</i>

Table 2.1: Beschreibung ausgewählter System Calls

Auch ein möglicher Angreifer muss um Schaden anzurichten also an den System Calls in irgendeiner Form eine Veränderung vornehmen. Entweder kann die Abfolge, also die Sequenz von System Calls verändert werden, z.B. es werden neue Funktionen aufgerufen, welche wiederum andere System Calls aufrufen, oder es werden die Argumente der System Calls verändert. So könnte zum Beispiel anstatt auf den Pfad „/tmp/some/file“ auf „/etc/passwd“ zugegriffen werden. Viele verschiedene IDS Ansätze betrachten lediglich die Sequenz von System Calls und missachten die in den Argumenten enthaltene Informationen. Auch wenn diese Ansätze teilweise sehr erfolgreich sind, lassen sie den Angreifenden einen Spielraum. Verschiedene Arbeiten [30], [27], [28] zeigen, wie dieser Spielraum ausgenutzt werden kann um unerkannt Angriffe durchzuführen. Tan et al. [28] erreichen dies durch die Veränderung eines zuvor von der IDS erkannten Angriffes. Sie beschreiben, wie dem IDS fremde System Call Sequenzen derart Verändert werden können, dass sie als normal eingestuft werden. Dabei werden die fremden Sequenzen auseinander gezogen und mit bekannten Sequenzen aufgefüllt. Ein weiterer Ansatz versucht lediglich die System Call Argumente zu verändern, ohne dabei die Sequenz zu beeinflussen [30]. Doch diese Beispiele zeigen auch, dass wenigstens ein Faktor, also Sequenz oder Argumente, verändert

Verwendeter
Algorithmus:
STIDE [6]

werden muss, um das Systemverhalten abzuwandeln. Welche dieser Argumente und wie diese genutzt werden können um die Anomalieerkennung zu verbessern soll in Kapitel 4.2.3 untersucht werden. Im dem nachfolgenden Kapitel wird nun auf verschiedene Datensätze, welche System Call Sequenzen enthalten, eingegangen.

2.4 DATENSATZ

Seit 1998 einer der ersten System Call Datensätze für HIDS veröffentlicht wurde [18], kamen verschiedene Datensätze hinzu. Auf diese wird in den kommenden Abschnitten kurz eingegangen. Dabei soll auch auf die Nutzbarkeit und die entstehenden Problematiken dieser für die HIDS über System Calls eingegangen werden.

KDD Der unter anderen von der *Defence Advanced Research Project Agency*, kurz DARPA, erstellte Datensatz KDD-99 [18] steht auf Grund verschiedener Unzulänglichkeiten schon länger in der Kritik [5] [29] [7]. Zum einen ist der Datensatz veraltet (1999) und zum anderen gibt es Diskrepanzen in den Daten, wie unter anderem von Vegard Engen beschrieben wird [5].

UNM Auch dieser Datensatz [7] ist veraltet (1999) und kommt für eine weitere Betrachtung nicht in Frage, da zusätzlich auch weitere Kontextinformationen wie Thread IDs fehlen [4]

ADFA-LD Der ADFA-LD Datensatz wurde von Hu et al. [4] im Jahre 2013 erstellt und ist damit wesentlich aktueller als die zuvor genannten. Aufzeichnungen wurden auf dem Betriebssystem Ubuntu 11.04 durchgeführt, allerdings wurden diese nicht gut dokumentiert was ein bearbeiten erschwert [1]. Erschwerend kommt hinzu, dass lediglich Sequenzen von System Call IDs aufgezeichnet wurden und damit keine Metadaten beinhalten.

NIGDS-DS Der 2017 erstellte Datensatz NIGDS-DS beinhaltet Thread Informationen, aber auch hier fehlen weitere Daten wie zum Beispiel System Call Argumente. Ein weiteres großes Problem liegt in der Ungenauigkeit der Zeitstempel, welche nur auf die Sekunde genau sind. Des Weiteren ergeben sich Schwierigkeiten in der Zuordnung von der beschriebenen Event ID und den Zeitstempeln.

LID-DS 2019 veröffentlichten Grimmer et al. [9] das *Leipzig Intrusion Detection-Data Set* (LID-DS). Sie erkannten, dass die bisherigen Datensätze entweder veraltet oder nicht ausreichend waren um zum Beispiel Thread IDs oder System Call Argumente für ein IDS zu verwenden. Im folgenden soll eine Beispieldatei betrachtet werden.

System Call								
event number	event time	cpu	user uid	process name	thread id	event direction	event type	event arguments
4012	10 : 18 : 20.1231231231	0	33	apache2	1425	>	writew	<i>fd</i> = 12(< 4t > 172.131.12.1 : 123 → 172.13.231.2 : 123)size = 2392

Table 2.2: Ausschnitt aus LID-DS [9]

Scenarien	
Name	Beschreibung
Bruteforce_CWE-307	Ungeeignete Einschränkung von übermäßigen Authentifizierungs Versuche
CVE-2012-2122	Umgehung von MySQL Authentifizierung
CVE-2014-0160	Heartbleed: Schwachstelle in OpenSSL
CVE-2017-7529	Nginx Integer Overflow
CVE-2018-3760	Sprockets Datenleck Schwachstelle
CVE-2019-5418	Rails Fileinhalt Offenlegung
EPS_CWE-434	EPS file upload: uneingeschränkter Upload von gefährlichen Dateitypen
PHP_CWE-434	PHP file upload: uneingeschränkter Upload von gefährlichen Dateitypen
SQL Injection	SQL Injection mit sqlmap
ZipSlip	blablabla

Table 2.3: Ausschnitt aus LID-DS [9]

Der Datensatz umfasst zehn verschiedene Angriffsscenarien, dargestellt in Tabelle 2.3. Jede Aufzeichnung eines Szenarios enthält ca. 1000 Files welche jeweils ca. 60sec Aufnahmen beinhalten. Dies führt zu insgesamt ungefähr 10h Trainingsdaten pro Szenario.

In den Testdaten sind *malicious* Files beinhaltet, welche eine Information über den Angriffszeitpunkt liefert. Jedoch gibt es bei einer *malicious* File im Gegensatz zu den normalen Files vier mögliche Zuordnungen. Befindet sich der Anomaliescore unter dem Schwellwert kann von einem *True Negative* eingestuft werden. Also es wurde korrekter weise kein Alarm vorhergesagt. Befindet sich der Anomaliescore vor dem Angriffszeitpunkt über dem Schwellwert liegt ein *False Positive* vor. Es wurde ein Alarm gemeldet an einer Stelle an dem kein Angriff stattfand. Nach dem angegebenen Angriffszeitpunkt wird es allerdings schwieriger. Denn liegt der Anomaliescore nach dem Angriffszeitpunkt über dem Schwellwert, wird von einem *True Positive*, also einem korrektem Alarm ausgegangen. Jedoch könnte da der Angriff schon vorbei sein, oder gar noch nicht gestartet sein. Es können nach dem Angriffszeitpunkt auch *False Positive* oder *False Negative* geben, welche allerdings nicht als solche erkannt werden

zu dt. schädlich

können. Wie sich das auf die Auswertung der Ergebnisse auswirkt wird in Kapitel 4.6 beleuchtet.

Nachdem nun verschiedene allgemeine Ansätze zur Erkennung von schädlichem Verhalten eines Systems und mögliche Datensätze zur Auswertung untersucht wurden, soll im Folgenden die Frage geklärt werden, wie Muster mit Hilfe von künstlichen neuronalen Netzen in einem Datensatz erkannt werden können.

2.5 KÜNSTLICHE NEURONALE NETZE

Das Nutzen von bestehenden und in der Natur vorkommenden Strukturen und Prozessen kommt in verschiedenen Forschungsbereichen zum Einsatz. In direkter Umsetzung von zum Beispiel der Struktur von Geckofüßen unter anderem für die Raumfahrt [32]. Auch Prozesse welche in der Natur beobachtbar sind werden versucht zu adaptieren, dazu zählen zum Beispiel Ameisenalgorithmen [22]. Ein in den letzten Jahren immer weiter verbreiteter Ansatz in der elektronischen Datenverarbeitung ist die Verwendung von künstlichen neuronalen Netzen. Dieser versucht sich die Struktur von Gehirnen anzueignen. Man verspricht sich mit dem Einsatz von künstlichen neuronalen Netzen, welche eine Varietät an verschiedenen Architekturen beinhalten, diverse Optimierungsprobleme zu lösen. Zu aktuellen Beispielen zählen dabei auch Vorhersagen die im Zusammenhang mit der Verbreitung des COVID-19 Virus stehen [25] [31] [21].

Algorithmen in welchen neuronale Netze zum Einsatz kommen bestehen generell aus zwei Phasen. In der ersten Phase, der Trainingsphase, werden vordefinierte Trainingsdaten in das Netz gegeben. Dieses versucht Merkmale in den Daten zu ermitteln, mit welchen dann in der Testphase Voraussagen gemacht werden können. Dabei haben sich spezialisierte Herangehensweisen entwickelt, wie zum Beispiel die *Convolutional Neural Nets* (CNN) für die Bilderkennung. Für sequentielle Daten wie Audio, Text und Video, bei welchen eine zeitliche Komponente entscheidend ist, eignen sich vor allem die *Recurrent Neural Nets* (RNN). Da in dieser Arbeit sequentielle Daten betrachtet werden, die sequentielle Abfolge von System Calls, soll im Folgenden nur auf die RNNs und besondere Abwandlungen dieser eingegangen werden.

2.5.1 Rekurrente neuronale Netze

Der entscheidende Unterschied von RNNs zu herkömmlichen neuronalen Netzen ist, dass der Ausgang eines Knotens auf einer *Layer* mit einer vorherigen oder derselben *Layer* verbunden ist. Ist dies der Fall spricht man von einem *Feedback* oder *Recurrent Neural Network*, sonst von einem *Feedforward Neural Network*. Mit Knoten, die eine extra Verbindung zu sich selbst haben, können frühere Eingaben Einfluss

zu dt. Ebene

auf die Behandlung der nächsten Eingabe haben. Der einzelne Knoten merkt sich seine Ausgabe, welche im nächsten Zeitschritt als weiteres Eingabesignal dient. Dadurch wird es ermöglicht auch zeitlich abhängige Sequenzen zu erlernen, da die Signalverarbeitung der RNNs auch vorherige Geschehnisse mit einbezieht. Im Gegensatz dazu steht zum Beispiel die Bilderkennung, bei welchem das vorherige Bild keinen Einfluss auf die Einschätzung des aktuellen Bildes hat. Dieser Zusammenhang lässt sich in der folgenden Gleichung darstellen.

$$\begin{aligned} h_t &= \sigma(W_h h_{t-1} + W_x x_t + b) \\ y_t &= h_t \end{aligned} \quad (2.1)$$

Dabei beschreiben x_t , h_t und y_t den Eingang des Neurons, die rekurrente Information und den Ausgang des RNN. W_h und W_x beschreiben die Gewichte und b den Bias. Ein einzelner Knoten wird ohne die Gewichte in Abbildung 2.2 dargestellt, sowie in Abbildung 2.3 in einer alternativen Darstellung, wie sich dieser Knoten über t Zeitpunkte verhält. Dabei werden für die Übersichtlichkeit Gewichte sowie der Bias nicht dargestellt. Doch auch die RNNs haben ein Problem bei Merk-




Figure 2.2: Darstellung einer RNN Zelle




Figure 2.3: Darstellung einer „ausgerollten“ und vereinfachten RNN Zelle

malen, die sich über einen längeren Zeitraum strecken. Denn dabei kommt es häufig vor, dass durch die Back Propagation die berechneten Gradienten entweder verschwindend klein, oder sehr groß werden. Gerade bei Abhängigkeiten über einen größeren zeitlichen Abstand tendieren die Fehlersignale, die durch die Back Propagation durch das Netz gegeben werden, zu geringe Gewichtsänderungen auszulösen.

Traditionelle Aktivierungsfunktionen wie die hyperbolische Tangensfunktion haben Gradienten im Bereich $(-1, 1)$ oder $[0, 1)$ und Backpropagation berechnet Gradienten durch die Kettenregel. Dies hat den Effekt, dass n dieser kleinen Zahlen multipliziert werden, um die Gradienten der „vorderen“ Schichten in einem n -Schichten-Netzwerk zu berechnen, was bedeutet, dass der Gradient (Fehlersignal) exponentiell mit n abnimmt und die vorderen Schichten sehr langsam trainieren. Die von Sepp Hochreiter erstmals erwähnte *Long Short-Term Memory* (LSTM) Zellen ermöglichen durch verbesserte Fehlerkorrektur stabilere Lernergebnisse sowie auch das Lernen von Mustern mit noch größeren zeitlichen Abständen. [12]

Diese Sonderform der RNNs, die auch in dieser Arbeit verwendet werden, sollen deshalb genauer untersucht werden.

2.5.2 Long Short-Term Memory

Hauptziel der LSTMs ist es, das Lernen der zeitlich abhängigen Muster zu verbessern. Entscheidend dafür ist die Einschätzung welche zuvor gesehenen Informationen für die aktuelle Eingabe relevant sein könnten.




Figure 2.4: Schematische Darstellung eines Knotens in einem LSTM NN, mit Input, Output und Forget Gate (inspiriert von [23]).

Und um zu erlernen welche früheren Ausgaben für die Ermittlung nächster Datenpunkte entscheidend sind, wird an jedem Knoten eine *Memory Cell* angebracht, zu sehen ist diese Erweiterung in Abbildung 2.4. Sie ist mit sich selbst verbunden, kennt also die vorherigen Ausgaben und gibt den Zellstatus an. Mit Hilfe dieser Information soll eine Abhängigkeit auch über einen längeren Zeitraum gefunden werden. Der Zellstatus C_{t-1} zum Zeitpunkt $t - 1$ hat im nächsten Zeitschritt t einen Einfluss auf den Zellstatus C_t und somit auch auf die Ausgabe y_t . Die Weitergabe des Status wird in Abbildung 2.5 dargestellt.

Einfluss auf den Zellstatus haben zwei verschiedene *Gates*. Im ersten Schritt wird entschieden, welche Information aus dem vorherigen Zeitschritt keinen Einfluss mehr auf den Zellstatus haben sollen. Dies

zu dt.
Gedächtniszelle

zu dt. Gatter/Tore




Figure 2.5: Weitergabe des Zellstatus innerhalb eines Knotens (inspiriert von [23]).

wird mit dem *Forget Gate* umgesetzt und ist in Abbildung 2.6 zu sehen und kann analog zur RNN Zelle folgendermaßen hergeleitet werden.

$$f_t = \sigma(W_{fh}h_{t-1} + W_{fx}x_t + b_f) \quad (2.2)$$

W_{fh} und W_{fx} beschreiben die Gewichte b_f den Bias des *Forget Gate*. Es wird also die vorherige Eingabe h_{t-1} sowie die aktuelle Eingabe x_t gewichtet und mit Bias an die Aktivierungsfunktion σ übergeben. Damit sollen Informationen aus dem Speicher, die keinen Einfluss mehr haben sollen, entfernt werden. In dem Sprachbeispiel könnte das Genus (*grammatikalisches Geschlecht*) gespeichert werden, um so eine grammatikalisch korrekte Vorhersage zu machen. Kommt nun allerdings ein neues Pronomen in der Eingabe x_t , sollte das bisher gespeicherte Genus keinen Einfluss mehr haben.




Figure 2.6: Einfluss des Forget Gates auf den Zellstatus (inspiriert von [23]).

Das *Input Gate* soll im nächsten Schritt angeben, welche neuen Informationen in den Zellstatus C_t aufgenommen werden. Dies erfolgt in zwei Schritten, zunächst wird mit i_t ermittelt, welche Information geupdated werden soll.

$$i_t = \sigma(W_{ih}h_{t-1} + W_{ix}x_t + b_i), \quad (2.3)$$

$$\tilde{C}_t = \tanh(W_{\tilde{C}h}h_{t-1} + W_{\tilde{C}x}x_t + b_{\tilde{C}}),$$

Im Vektor \tilde{C} sind mögliche Kandidaten enthalten (wie z.B. das Genus), welcher den zuvor vergessenen Wert ersetzen soll (vgl. Abbildung 2.7). Der gesamte Zellstatus C_t wird dann zusammen mit Werten aus dem *Forget Get* verrechnet.

$$C_t = f_t \times C_{t-1} + i_t \times \tilde{C}_t, \quad (2.4)$$




Figure 2.7: Einfluss des Input Gates auf den Zellstatus (inspiriert von [23]).

Wie der Zellstatus C_t nun die Ausgabe beeinflusst, wird über das *Output Gate* geregelt (siehe Abbildung 2.8).

$$\begin{aligned} o_t &= \sigma(W_{oh}h_{t-1} + W_{ox}x_t + b_o), \\ h_t &= o_t \tanh(c_t) \end{aligned} \quad (2.5)$$

Dies soll in unserem Sprachbeispiel entscheiden, ob die Information des Genus für die Vorhersage des nächsten Wortes eine Rolle spielt. [8] [23]




Figure 2.8: Das Output Gate regelt den Einfluss des Zellstatus auf die Ausgabe des Neurons (inspiriert von [23]).

Die verschiedenen Gates können so als ein weiteres kleines NN in jedem Knoten der LSTM Netze betrachtet werden, welche einen

zeitlichen Zusammenhang besser erkennen sollen. Gesamt lässt sich eine LSTM Zelle mit den folgenden Formeln beschreiben:

$$\begin{aligned}
 f_t &= \sigma(W_{fh}h_{t-1} + W_{fx}x_t + b_f) \\
 i_t &= \sigma(W_{ih}h_{t-1} + W_{ix}x_t + b_i), \\
 \tilde{C}_t &= \tanh(W_{\tilde{C}h}h_{t-1} + W_{\tilde{C}x}x_t + b_{\tilde{C}}), \\
 C_t &= f_t \times C_{t-1} + i_t \times \tilde{C}_t, \\
 o_t &= \sigma(W_{oh}h_{t-1} + W_{ox}x_t + b_o), \\
 h_t &= o_t \tanh(c_t) \\
 y_t &= h_t
 \end{aligned} \tag{2.6}$$

VERWANDTE ARBEITEN

3.1 ANOMALIEDETEKTION MIT SYSTEM CALLS

3.2 UNTERSUCHEN VON ZEITREIHEN MIT LSTM

REALISIERUNG

4.1 VERWENDETE TOOLS

Tensorflow Keras Rechencluster clara sysdig

4.2 VORVERARBEITUNG

Gegeben 10 szenarios mit ca. 1000 files durchschnittlich 45sec in runs.csv genauere beschreibung files mit label und zeitangabe falls exploit falls kein exploit dann exploit start time -1 keine dauer des exploits also ende nicht bekannt nicht syscall genau start des angriffs angegeben führe puffer ein, da angegebener Zeitpunkt ungenau, sodass auch wirklich jeder angriff nach exploit start time alles nach dem angriffszeitpunkt muss als anomalie gewertet werden, auch wenn angriff evtl noch nicht gestartet hat oder schon vorbei. Ungenauigkeiten auf die in der Auswertung der Daten noch einmal genauer eingegangen wird filtern von switch statements in Datensatz weil keine system calls nur öffnende syscalls keine schließenden

Neuronale netze benötigen numerische werte deswegen umwandlung sys to int unbrauchbar für netz auf Grund aktivierungsfunktion $\rightarrow 2 > 1 \ 3 > 1$ mittelwert 2

- syscall to int: Wandle Syscall name in Integer um
ohe of sysint: use ohe for every syscall $n * (\text{distinct calls} + 1)$
eingabeneuronen
w2v von syscall weniger neuronen und nähe von syscall!!!
- ngram bilden: Bilde entsprechend angegebenes n ngramm

4.2.1 *Thread Awareness*

syscalls welche nicht in trainingsdaten bekommen eine o ngramme thread aware bilden

4.2.2 *Embedding*

ohe und w2v word embedding parameterwahl wichtig $\sqrt{\text{distinct}}$
Threadid kodieren:

- use entity embedding for ThreadID [10]

- relationship between threads and reduce size (possible 1000 different threads)
- choose size of embedding -thumbrule $\sqrt{\text{unique value}}$

zeit kodieren

- use time delta of two different syscalls as new input

parameterlänge kodieren

4.2.3 *System Call Argumente*

STRING LENGTH

STRING CHARACTER DISTRIBUTION

STRUCTURAL INFERENCE

TOKEN FINDER

4.2.4 *Parameterwahl*

N gram länge lstm merkt sich vorherige syscalls aber hinzunahme von syscalls weitere info -> finden von sweet spot generell großes n viele alarme kleines n weniger alarme —> vorteil LSTM? wichtiger Parameter den es zu ermitteln gilt

4.3 ALGORITHMUS

LSTM Sprachmodell soll Wahrscheinlichkeit des nächsten System Calls vorhersagen, gegeben eines System Calls oder einer Sequenz von System Calls. Gab es in den Trainingsdaten die feste Menge $S = 1, \dots, N$ an System Calls, so gibt $x = x_1 \dots x_l$ ($x_i \in S$) die Sequenz an l System Calls an. Jeder dieser System Calls bekommt im ersten Schritt einen Integerwert zwischen 1 und N . Taucht in den Testdaten nun ein noch nicht bekannter System Call x_i auf, also $x_i \notin S$, so erhält dieser den vorläufigen Wert 0. Zu jedem Zeitpunkt wird x_i der Input Layer übergeben. Dabei wird ein Embedding aus Abschnitt 4.2.2 verwendet. Mit den gegebenen Trainingsdaten kann nun das LSTM mittels des *back-propagation through time* (BPTT) trainiert werden. An der Ausgangs Layer befindet sich eine Softmax Aktivierungsfunktion. Diese wird verwendet um die Ausgabe zu normalisieren und damit die Wahrscheinlichkeitsverteilung des nächsten System Calls zu erhalten. Also $P(x_i | x_{1:i-1})$ für alle i .

4.4 ANOMALIEERKENNUNG

Es kann also bei Auftreten des System Calls x_i überprüft werden mit welcher Wahrscheinlichkeit p dieser vorhergesagt wurde. Der eigentliche Anomalie-Score wird dann folgenderweise berechnet:

$$ascore = 1 - p \quad (4.1)$$

Unterschreitet dieser einen Schwellwert so wird dies als eine Anomalie gewertet und ein Alarm angezeigt.

4.4.1 Schwellwertbestimmung

Um den zuvor erwähnten Schwellwert automatisch zu bestimmen, wird der Algorithmus auf die Validierungsdaten angewendet. Dabei dient der höchste Wert dieser Daten dann als Schwellwert, da angenommen wird, dass mindestens alle Daten aus den Validierungsdaten harmlos sind und damit unter dem Schwellwert liegen sollten. Wichtig ist dabei dafür nicht die Trainingsdaten zu wählen, da eine starke Verzerrung der Schwellwertes durch Overfitting der Daten entstehen könnte. Das würde bedeuten, dass nur sehr geringe Anomaliewerte auftreten und der Schwellwert sehr gering ist und damit die Gefahr für viele Fehlalarme besteht.

Alternativ betrachte die x wahrscheinlichsten vorhergesagten system calls, falls tatsächlicher system call nicht dabei \rightarrow alarm x ermitteln, betrachte validierungsdaten und schaue ob schlechtestes x aussehen würde tatsächlich oft einmal schlechteste platzierung und automatische erkennung von x schwer.

4.5 STRUKTURIERUNG DER EXPERIMENTE

Um aussagekräftige Experimente zu entwickeln müssen zuerst Überlegungen zur praktischen umsetzung gemacht werden dabei wird in ersten Tests klar, dass zeit hierbei eine große rolle spielen wird

erste Tests also ausgelegt um Faktoren zu ermitteln, welche die auswertungen stark verlangsamen und diese ausschließen.

4.5.1 Faktor Zeit

zeit/dr als groesse und farbe von scatter plot batch size test und train x/y achse

eingrenzen von moeglichen konfigurationen

Berechnungszeiten aus verschiedenen Perspektiven relevant: soll live system werden begrenzte rechenleistung und viele Tests zur auswertung von parametern architektur etc erster test zur abschätzung diverser zeitl. faktoren:

Faktoren:

- Architektur
- Verarbeitung Stream
ngram größe
- embedding

ngram größe, architektur und verwendung w2v statt ohe Grobe Abschätzung der Zeit, da Berechnungen auf Clustern ausgeführt werden von Auslastung beeinflusst werden. Klare Erkenntnisse:

Single Small 50 neuronen eine schicht : Single Big 250 neuronen eine schicht multi 50 neuronrn 3 schichten

erste Abschätzung von Nutzen von Thread einführen von stateful sowie Batch Normalization

4.5.2 Optimale Parameter

ARCHITEKTUR versch architekturen: Single Small 50 neuronen eine schicht Single Big 250 neuronen eine schicht multi small 20 neuronen 3 schichten multi big 50 neuronrn 3 schichten deep erste 50 sonst 20 6 schichten

singlesmall 43% von Deep insgesamt am schnellsten single small wie zu erwarten, deep am langsamsten

HYPERPARAMETER <++> aktivierungs funktion -> dense layer with softmax or tanh batch size learning rate optimizer

NGRAM GRÖSSE ngram größer -> langsamer

EMBEDDING overhead berechnung embedding, muss allerdings nur einmal berechnet werden zu erkennen w2v mit embedding size = 2 und window = 4 wesentlich schneller embedding größer -> langsamer

vergleich ngram im schnitt mit ngram gr 2 84% von ngr 3 und w2v bringt entscheidenden Vorteil gegenüber ohe: Jeweils vergleich der selben parameter außer w2v vs ohe: Single small w2v nur 30% der zeit gegenüber single small ohe bei mulit w2v sogar nur 13% im mittel über alle architekturen 21.5% der Zeit von ohe bei verwendung w2v

ARCHITEKTUR teste eine schicht viele neuronen eine schicht wenige neuronen mehrere schichten mehrere neuronen / mit dropout dazwischen viele schichten wenige neuronen / mit dropout dazwischen

auf Grund des zeitlichen Faktors fallen Deep und multibig weg Also zu testen: Single Small Single Multi Small Multi

EMBEDDING w2v bringt verbesserung: alles ohne thread nur w2v!!

THREADINFO Hypothese: Threadinfos bringen was

Einbinden von thread information auf verschiedenen wegen: Thread aware ngrams (tan) Thread aware ngrams for w2v (tanw2v) Thread change flag (tcf)

varianten: tan tanw2v tcf tan tcf tan tanw2v tcf tanw2v tan tanw2v tcf

—> welcher dieser varianten am besten?

PARAMETER args time

LSTM ohne Threadinfos mit OHE LSTM mit W2V ohne Threadinfos (ngram) LSTM mit W2V mit Threadinfos (ngram) LSTM mit W2V threadaware mit Threadinfos (ngram) LSTM mit W2V threadaware mit Threadinfos (ngram) und threadchangeflag LSTM mit W2Vthreadaware mit Threadinfos (ngram) und threadchangeflag, spezialtraining -> LSTM final

Manche angriffe verändern Sequenz von syscalls nicht Hypothese: verwende Parameter um erg zu verb

LSTM final + strlen LSTM final + time delta LSTM final + strlen + time delta

4.6 METRIKEN

Auf Grund dessen Metrik False Alarm/ consecutive false alarm und Detection rate falls einmal pro malicious file in quadrant 4 -> HIT Wahl von Metriken in NN Precision, Recall, f-score, TNR, FNR, FPR

problematisch: nicht auf syscall genau gelabelt recall precision usw nur auf file ebene: alarm nach exploitstarttime wird immer als hit gewertet -> aber evtl angriff noch nicht begonnen oder angriff bereits vorbei ebenso umgekehrt, eig muss jeder nicht alarm nach exploitstart als FN gewertet werden weswegen filegenau geschaut wird vorteil des Datensatzes gegenüber anderen, immerhin exploitstart time

alarm in quadrant —> image

IMPLEMENTIERUNG

Verschiedene Komponenten um Modelle in Python umzusetzen zunächst soll auf vorverarbeitung eingegangen werden

5.1 ERSTELLEN DER TRAININGSDATEN

5.1.1 *w2v*

verschiedene varianten mit ignore thread info

5.1.2 *Parameterinfo*

ERGEBNISSE

6.0.1 Optimale Parameter

ARCHITEKTUR versch architekturen: Single Small 50 neuronen eine schicht Single Big 250 neuronen eine schicht multi small 20 neuronen 3 schichten multi big 50 neuronrn 3 schichten deep erste 50 sonst 20 6 schichten

singlesmall 43% von Deep insgesamt am schnellsten single small wie zu erwarten, deep am langsamsten

HYPERPARAMETER <++> aktivierungs funktion -> dense layer with softmax or tanh batch size learning rate optimizer

NGRAM GRÖSSE ngram größer -> langsamer

EMBEDDING overhead berechnung embedding, muss allerdings nur einmal berechnet werden zu erkennen w2v mit embedding size = 2 und window = 4 wesentlich schneller embedding größer -> langsamer

vergleich ngram im schnitt mit ngram gr 2 84% von ngr 3 und

w2v bringt entscheidenden Vorteil gegenüber ohe: Jeweils vergleich der selben parameter außer w2v vs ohe: Single small w2v nur 30% der zeit gegenüber single small ohe bei mulit w2v sogar nur 13% im mittel über alle architekturen 21.5% der Zeit von ohe bei verwendung w2v

ARCHITEKTUR teste eine schicht viele neuronen eine schicht wenige neuronen mehrere schichten mehrere neuronen / mit dropout dazwischen viele schichten wenige neuronen /mit dropout dazwischen

auf Grund des zeitlichen Faktors fallen Deep und multibig weg Also zu testen: Single Small Single Multi Small Multi

EMBEDDING w2v bringt verbesserung: alles ohne thread nur w2v!!

THREADINFO Hypothese: Threadinfos bringen was

Einbinden von thread information auf verschiedenen wegen: Thread aware ngrams (tan) Thread aware ngrams for w2v (tanw2v) Thread change flag (tcf)

varianten: tan tanw2v tcf tan tcf tan tanw2v tcf tanw2v tan tanw2v tcf

—> welcher dieser varianten am besten?

PARAMETER args time

LSTM ohne Threadinfos mit OHE LSTM mit W2V ohne Threadinfos (ngram) LSTM mit W2V mit Threadinfos (ngram) LSTM mit W2V threadaware mit Threadinfos (ngram) LSTM mit W2V threadaware mit Threadinfos (ngram) und threadchangeflag LSTM mit W2Vthreadaware mit Threadinfos (ngram) und threadchangeflag, spezialtraining -> LSTM final

Manche angriffe verändern Sequenz von syscalls nicht Hypothese: verwende Parameter um erg zu verb

LSTM final + strlen LSTM final + time delta LSTM final + strlen + time delta

BIBLIOGRAPHY

- [1] Adamu I Abubakar, Haruna Chiroma, Sanah Abdullahi Muaz, and Libabatu Baballe Ila. "A review of the advances in cyber security benchmark datasets for evaluating data-driven based intrusion detection systems." In: *Procedia Computer Science* 62 (2015), pp. 221–227.
- [2] M. H. Bhuyan, D. K. Bhattacharyya, and J. K. Kalita. "Network Anomaly Detection: Methods, Systems and Tools." In: *IEEE Communications Surveys Tutorials* 16.1 (2014), pp. 303–336. DOI: [10.1109/SURV.2013.052213.00046](https://doi.org/10.1109/SURV.2013.052213.00046).
- [3] Varun Chandola, Arindam Banerjee, and Vipin Kumar. "Anomaly Detection: A Survey." In: *ACM Comput. Surv.* 41.3 (July 2009). ISSN: 0360-0300. DOI: [10.1145/1541880.1541882](https://doi.org/10.1145/1541880.1541882). URL: <https://doi.org/10.1145/1541880.1541882>.
- [4] Gideon Creech and Jiankun Hu. "Generation of a new IDS test dataset: Time to retire the KDD collection." In: *2013 IEEE Wireless Communications and Networking Conference (WCNC)*. IEEE. 2013, pp. 4487–4492.
- [5] Vegard Engen. "Machine learning for network based intrusion detection: an investigation into discrepancies in findings with the KDD cup'99 data set and multi-objective evolution of neural network classifier ensembles from imbalanced data." PhD thesis. Bournemouth University, 2010.
- [6] S. Forrest, S. A. Hofmeyr, A. Somayaji, and T. A. Longstaff. "A sense of self for Unix processes." In: *Proceedings 1996 IEEE Symposium on Security and Privacy*. 1996, pp. 120–128. DOI: [10.1109/SECPRI.1996.502675](https://doi.org/10.1109/SECPRI.1996.502675).
- [7] S. Forrest and University of New Mexico. *University of New Mexico (UNM) Intrusion Detection Dataset*. URL: <https://www.cs.unm.edu/~immsec/systemcalls.htm>.
- [8] Felix A. Gers, Jürgen A. Schmidhuber, and Fred A. Cummins. "Learning to Forget: Continual Prediction with LSTM." In: *Neural Comput.* 12.10 (Oct. 2000), pp. 2451–2471. ISSN: 0899-7667. DOI: [10.1162/089976600300015015](https://doi.org/10.1162/089976600300015015). URL: <http://dx.doi.org/10.1162/089976600-300015015>.
- [9] Martin Grimmer, Martin Max Röhling, D Kreusel, and Simon Ganz. "A modern and sophisticated host based intrusion detection data set." In: *IT-Sicherheit als Voraussetzung für eine erfolgreiche Digitalisierung* (2019), pp. 135–145.

- [10] Cheng Guo and Felix Berkhahn. "Entity embeddings of categorical variables." In: *arXiv preprint arXiv:1604.06737* (2016).
- [11] S. He, J. Zhu, P. He, and M. R. Lyu. "Experience Report: System Log Analysis for Anomaly Detection." In: *2016 IEEE 27th International Symposium on Software Reliability Engineering (ISSRE)*. 2016, pp. 207–218. DOI: [10.1109/ISSRE.2016.21](https://doi.org/10.1109/ISSRE.2016.21).
- [12] Sepp Hochreiter. "The vanishing gradient problem during learning recurrent neural nets and problem solutions." In: *International Journal of Uncertainty, Fuzziness and Knowledge-Based Systems* 6.02 (1998), pp. 107–116.
- [13] Sepp Hochreiter and Jürgen Schmidhuber. "LSTM Can Solve Hard Long Time Lag Problems." In: *Proceedings of the 9th International Conference on Neural Information Processing Systems*. NIPS'96. MIT Press, 1996.
- [14] Ansam Khraisat, Iqbal Gondal, Peter Vamplew, and Joarder Kamruzzaman. "Survey of intrusion detection systems: techniques, datasets and challenges." In: *Cybersecurity* 2.1 (2019), pp. 1–22.
- [15] Vipin Kumar. "Parallel and distributed computing for cybersecurity." In: *IEEE Distributed Systems Online* 6.10 (2005).
- [16] *Leipzig Intrusion Detection Data Set*. URL: <https://www.exploids.de/lid-ds/>.
- [17] Hung-Jen Liao, Chun-Hung Richard Lin, Ying-Chih Lin, and Kuang-Yuan Tung. "Intrusion detection system: A comprehensive review." In: *Journal of Network and Computer Applications* 36.1 (2013), pp. 16–24.
- [18] Lincoln Laboratory MIT. *DARPA Intrusion Detection Evaluation Data Set*. 1998-2000. URL: <https://www.ll.mit.edu/r-d/datasets>.
- [19] F. Maggi, M. Matteucci, and S. Zanero. "Detecting Intrusions through System Call Sequence and Argument Analysis." In: *IEEE Transactions on Dependable and Secure Computing* 7.4 (2010), pp. 381–395. DOI: [10.1109/TDSC.2008.69](https://doi.org/10.1109/TDSC.2008.69).
- [20] Chad R Meiners, Jignesh Patel, Eric Norige, Alex X Liu, and Eric Torng. "Fast regular expression matching using small TCAM." In: *IEEE/Acm Transactions On Networking* 22.1 (2013), pp. 94–109.
- [21] Patricia Melin, Julio Cesar Monica, Daniela Sanchez, and Oscar Castillo. "Multiple Ensemble Neural Network Models with Fuzzy Response Aggregation for Predicting COVID-19 Time Series: The Case of Mexico." In: *Healthcare* 8.2 (2020). ISSN: 2227-9032. DOI: [10.3390/healthcare8020181](https://doi.org/10.3390/healthcare8020181). URL: <https://www.mdpi.com/2227-9032/8/2/181>.

- [22] Daniel Merkle and Martin Middendorf. "Ant colony optimization with global pheromone evaluation for scheduling a single machine." In: *Applied Intelligence* 18.1 (2003), pp. 105–111.
- [23] Christopher Olah. *Understanding LSTM Networks*. Aug. 2015. URL: <https://colah.github.io/posts/2015-08-Understanding-LSTMs/>.
- [24] Animesh Patcha and Jung-Min Park. "An overview of anomaly detection techniques: Existing solutions and latest technological trends." In: *Computer networks* 51.12 (2007), pp. 3448–3470.
- [25] Refat Khan Pathan, Munmun Biswas, and Mayeen Uddin Khan-daker. "Time series prediction of COVID-19 by mutation rate analysis using recurrent neural network-based LSTM model." In: *Chaos, Solitons & Fractals* 138 (2020), p. 110018.
- [26] *Seeing is Securing For containers, Kubernetes and cloud services*. URL: <https://sysdig.com/>.
- [27] Kymie MC Tan, Kevin S Killourhy, and Roy A Maxion. "Undermining an anomaly-based intrusion detection system using common exploits." In: *International Workshop on Recent Advances in Intrusion Detection*. Springer. 2002, pp. 54–73.
- [28] Kymie MC Tan and Roy A Maxion. "" Why 6?" Defining the operational limits of stide, an anomaly-based intrusion detector." In: *Proceedings 2002 IEEE Symposium on Security and Privacy*. IEEE. 2002, pp. 188–201.
- [29] Amjad M. Al Tobi and Ishbel Duncan. "KDD 1999 generation faults: a review and analysis." In: *Journal of Cyber Security Technology* 2.3-4 (2018), pp. 164–200. DOI: [10.1080/23742917.2018.1518061](https://doi.org/10.1080/23742917.2018.1518061). eprint: <https://doi.org/10.1080/23742917.2018.1518061>. URL: <https://doi.org/10.1080/23742917.2018.1518061>.
- [30] David Wagner and Paolo Soto. "Mimicry attacks on host-based intrusion detection systems." In: *Proceedings of the 9th ACM Conference on Computer and Communications Security*. 2002, pp. 255–264.
- [31] Peipei Wang, Xinqi Zheng, Gang Ai, Dongya Liu, and Bangren Zhu. "Time series prediction for the epidemic trends of COVID-19 using the improved LSTM deep learning method: Case studies in Russia, Peru and Iran." In: *Chaos, Solitons & Fractals* 140 (2020), p. 110214.
- [32] Gregory S Watson, David W Green, Lin Schwarzkopf, Xin Li, Bronwen W Cribb, Sverre Myhra, and Jolanta A Watson. "A gecko skin micro/nano structure—A low adhesion, superhydrophobic, anti-wetting, self-cleaning, biocompatible, antibacterial surface." In: *Acta biomaterialia* 21 (2015), pp. 109–122.